

FreeVCを用いた声質変換に基づく咽喉マイク音声認識

静岡大学情報学部 塚越駿大 西田昌史 西村雅史

1. 研究背景

咽喉マイク

- 咽喉付近に接触して装着させるマイク
- 皮膚振動を直接音声として収録

一般的な接話マイクに比べて
外部雑音に頑健

期待される活用場面



騒音環境下での 多人数会話での
音声認識
外部雑音や発話重量の影響を受け
やすい音声認識タスクに適用可能


咽喉マイクのデメリット

- 一般的な接話マイクとの音響差異
例) 高周波数帯の情報の欠落


既存の音声認識モデルでは音響特性
のミスマッチにより認識精度が低下

- 咽喉マイク音声の大規模なコーパスはない

接話マイク音声



咽喉マイク音声




2. 目的

少量の咽喉マイク音声を最大限に活用した、咽喉マイク音声認識モデルの作成

3. 提案手法


1. FreeVC^[1]を用いた咽喉マイク→接話マイクの特徴マッピング

➢ 学習時のモデル構造



- 学習には接話マイク音声のみを使用
- 特徴量抽出から波形生成までを1ステージで学習
- 自己教師あり事前学習モデルにはWavLM-large^[2]を利用
(WavLM-large: Libri-Light (60,000h) + GigaSpeech (10,000h) + VoxPopuli (24,000h))

➢ 特徴マッピング時のモデル構造




1. 咽喉マイク音声より言語情報を抽出
2. 接話マイク音声の特徴を付与
3. 音声を合成

新規性

- ✓ マッピングモデルに自己教師あり事前学習モデルとGANを同時に組み込んだ点
- ✓ 大規模音声コーパスによる事前知識とGANによる自然な音声合成を両立することが可能

2. 変換後の生成接話マイク音声を用いた音声認識モデルのFine-Tuning



➢ 音声認識モデル

- wav2vec事前学習モデル^[3]をCSJコーパスでFine-Tuningしたモデルを事前音声認識モデルとして利用
- 生成接話マイク音声を用いて事前音声認識モデルをFine-Tuning

4. 評価実験

➢ 利用したデータ

- 学習データ
男性話者29名分の音素バランス文(ATR503)読み上げ音声(約15h)
- テストデータ
学習話者を除く男性話者10名による新聞記事読み上げ音声(約1h)

➢ 評価指標

- 文字誤り率(CER)で評価 $CER = (\text{挿入語数} + \text{置換語数} + \text{削除語数}) / \text{正解語数}$

➢ 提案手法

FreeVC: 咽喉マイク音声をFreeVCで接話マイク音声に変換しただけの場合
FreeVC+Fine_Tuning: 上記に加え音声認識部のfine-tuningを行うモデル

➢ 比較結果

(比較対象)	CER(%)
接話マイク	3.95
咽喉マイク	24.02
(提案対象)	
FreeVC	16.51
FreeVC+Fine_Tuning	13.05

接話マイク音声に変換するだけでも、約7.5%の誤り率削減

- 咽喉マイクから接話マイクへと特徴マッピングをした後、音声認識部のFine-Tuningをした結果、約11%誤り率が削減
- 一方で接話マイク音声の認識精度には程遠い結果

5. 考察

- 「ちぢまって」→「ちげまって」, 「ちんぎん」→「しんじん」を例に言い換えが発生
- WavLMは接話マイク音声で学習→ 咽喉マイクに対応していない
- 言語特徴抽出部がボトルネックになっているのではないか
- 咽喉マイクで学習を行い、接話マイク→咽喉マイクとすれば、WavLMによる事前知識をより活用できる

➢ 認識結果の一例

企;業;規;模;別;の;賃;金;格;差;も;少;し;ず;つ;縮;<eps>;ま;つ;て;き;た
=;=;=;=;=;=;S;S;S;S;S;=;=;=;=;S;I;=;=;=;=;=;=;
企;業;規;模;別;の;賃;金;格;差;も;少;し;ず;つ;縮;ち;げ;ま;つ;て;き;た

6. まとめ

- 声質変換に基づいて咽喉マイク音声から接話マイク音声へ特徴マッピングすることで、既存の音声認識モデルでの認識精度を向上させることが可能
- 今後は声質変換モデルを用いて大規模なコーパスから疑似咽喉マイク音声を作成し、データ拡張を行うことを試みる